

1. [2pkt] Przy każdym zdaniu zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) W minimum globalnym różniczkowalnej funkcji jednej zmiennej na przedziale $[a, b]$ zeruje się pochodna.
- (b) Liniowy rząd zbieżności oznacza, że odległość od optimum maleje liniowo z liczbą iteracji.
- (c) Kwadratowy rząd zbieżności oznacza, że błąd optymalizacji maleje w tempie podwójnie wykładniczym.
- (d) Jeśli $f(\mathbf{x}) \geq f(\mathbf{y}) + \nabla f(\mathbf{y})^\top (\mathbf{x} - \mathbf{y})$ dla dowolnych \mathbf{x}, \mathbf{y} z dziedziny, to f jest wypukła.
- (e) Funkcja wypukła może osiągać minimum globalne w więcej niż jednym punkcie dziedziny
- (f) Punkt stacjonarny z dodatnio określonym hesjanem oznacza minimum lokalne.

2. [2pkt] Przy każdym zdaniu dotyczącym metod jednowymiarowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Jeśli pochodna jednowymiarowej funkcji jednomodalnej równa jest zero w danym punkcie to znajduje się tam minimum.
- (b) Metoda złotego podziału wymaga średnio mniej odwołań do funkcji by znaleźć rozwiązanie od metody przeszukiwania dychotomicznego.
- (c) Dla funkcji kwadratowej przeszukiwanie dychotomiczne znajduje optymalne rozwiązanie w jednym kroku.
- (d) Metoda bisekcji jest metodą bezgradientową.
- (e) Metoda przeszukiwania dychotomicznego może nie znaleźć minimum jeśli funkcja nie jest jednomodalna.
- (f) Metoda przeszukiwania dychotomicznego wymaga aby funkcja była różniczkowalna w badanym przedziale.

3. [3pkt] Używając operacji zachowujących wypukłość, pokaż, że funkcja $f: \mathbb{R}^3 \rightarrow \mathbb{R}$:

$$f(x, y, z) = e^{(x-y)^2} - 2x + z^2,$$

jest wypukła.

Odp:

4. [4pkt] Rozważ minimalizację funkcji dwóch zmiennych:

$$f(x, y) = e^{x+y} - 2x + y^2$$

Rozpoczynając od punktu $(x_0, y_0) = (1, -1)$ wykonaj jeden krok:

- metodą spadku wzdłuż gradientu z długością kroku $\alpha = 1$,
- metodą Newtona-Raphsona.

Wyznacz pochodne cząstkowe $f(x, y)$:

Stąd $\nabla f(x_0, y_0) =$

Wyznacz drugie pochodne cząstkowe $f(x, y)$:

Stąd $\nabla^2 f(x_0, y_0) =$

$(\nabla^2 f(x_0, y_0))^{-1} =$

Rozwiązanie po pierwszym kroku algorytmu spadku wzdłuż gradientu (napisz wzór ogólny i wartość liczbową):

$\mathbf{x}_1 = (x_1, y_1) =$

Pierwszy krok algorytmu Newtona-Raphsona (napisz wzór ogólny i wartość liczbową):

$\mathbf{x}_1 = (x_1, y_1) =$

5. [2pkt] Przy każdym zdaniu dotyczącym metody gradientów sprzężonych (MGS) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Wektory $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ i $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ są sprzężone względem $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$.
 - (b) Wektory $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ i $\begin{bmatrix} -1 \\ 1 \end{bmatrix}$ są sprzężone względem $\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$.
 - (c) Punkt minimum dowolnej funkcji różniczkowalnej jest kombinacją liniową wektorów sprzężonych.
 - (d) MGS zastosowany do dowolnej funkcji wypukłej kończy działanie po n krokach (gdzie n to liczba zmiennych).
 - (e) MGS jest metodą spadkową.
 - (f) Kierunek sprzężony \mathbf{v}_k wybrany w k -tej iteracji MGS jest prostopadły do gradientu w tej iteracji, $\mathbf{g}_k = \nabla f(\mathbf{x}_k)$.
6. [2pkt] Przy każdym zdaniu dotyczącym omówionych metod spadkowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Metoda najszybszego spadku wzdłuż gradientu gwarantuje znalezienie minimum globalnego funkcji różniczkowalnej.
 - (b) Wskaźnik uwarunkowania macierzy wypukłej funkcji kwadratowej równy jedności gwarantuje znalezienie minimum w jednym kroku metody Cauchy'ego.
 - (c) Metoda Levenberga-Marquardta i spadku wzdłuż gradientu działają identycznie dla funkcji kwadratowej.
 - (d) Metoda Newtona-Raphsona zainicjowana dostatecznie blisko minimum (z dodatnio określonym hesjanem) zbiega z kwadratowym rzędem zbieżności.
 - (e) Niezerowy gradient wewnątrz dziedziny funkcji oznacza istnienie w tym punkcie kierunku spadkowego.
 - (f) Metoda spadku wzdłuż gradientu z regułą Armijo zastosowana do funkcji wypukłej gwarantuje spadek funkcji celu (o ile nie zeruje się gradient).
7. [2pkt] Przy każdym zdaniu dotyczącym metody stochastycznego spadku wzdłuż gradientu (SGD) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Jedna iteracja algorytmu SGD zainicjalizowanego w minimum funkcji nie będzie miała żadnego efektu (nie zmieni aktualnego rozwiązania).
 - (b) Kierunek zmian w danej iteracji algorytmu SGD jest średnio równy ujemnemu gradientowi funkcji celu.
 - (c) Algorytm SGD można zastosować do optymalizacji regresji liniowej z niekwadratowym błędem o następującej postaci: $f(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{x}_i^T \mathbf{w})^4$.
 - (d) Zbieżność algorytmu SGD jest taka sama jak klasycznego algorytmu spadku wzdłuż gradientu (tj. liniowa).
 - (e) Algorytm SGD optymalizujący funkcję wypukłą, ze stałą długością kroku i nieskończenie dużą liczbą iteracji, znajdzie minimum lokalne funkcji.
8. [3pkt] Pokaż, że jeśli \mathbf{v}_k jest dowolnym kierunkiem poprawy w k -tej iteracji dla różniczkowalnej funkcji f , a nowy punkt $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{v}_k$ zostaje wybrany poprzez optymalizację długości kroku (tzn. $\alpha_k = \arg\min_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{v}_k)$, załóż, że takie α_k istnieje), to gradient w nowym punkcie jest prostopadły do \mathbf{v}_k , tzn. $\nabla f(\mathbf{x}_{k+1})^T \mathbf{v}_k = 0$. W szczególności, pokaż, że wynika z tego twierdzenie o "zygzakowaniu" dla metody Cauchy'ego.

Klucz rozwiązań

Optymalizacja ciągła, Test zaliczeniowy, grupa: A

1. [2pkt] Przy każdym zdaniu zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) W minimum globalnym różniczkowalnej funkcji jednej zmiennej na przedziale $[a, b]$ zeruje się pochodna.
- (b) Liniowy rząd zbieżności oznacza, że odległość od optimum maleje liniowo z liczbą iteracji.
- (c) Kwadratowy rząd zbieżności oznacza, że błąd optymalizacji maleje w tempie podwójnie wykładniczym.
- (d) Jeśli $f(\mathbf{x}) \geq f(\mathbf{y}) + \nabla f(\mathbf{y})^\top (\mathbf{x} - \mathbf{y})$ dla dowolnych \mathbf{x}, \mathbf{y} z dziedziny, to f jest wypukła.
- (e) Funkcja wypukła może osiągać minimum globalne w więcej niż jednym punkcie dziedziny
- (f) Punkt stacjonarny z dodatnio określonym hesjanem oznacza minimum lokalne.

2. [2pkt] Przy każdym zdaniu dotyczącym metod jednowymiarowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Jeśli pochodna jednowymiarowej funkcji jednomodalnej równa jest zero w danym punkcie to znajduje się tam minimum.
- (b) Metoda złotego podziału wymaga średnio mniej odwołań do funkcji by znaleźć rozwiązanie od metody przeszukiwania dychotomicznego.
- (c) Dla funkcji kwadratowej przeszukiwanie dychotomiczne znajduje optymalne rozwiązanie w jednym kroku.
- (d) Metoda bisekcji jest metodą bezgradientową.
- (e) Metoda przeszukiwania dychotomicznego może nie znaleźć minimum jeśli funkcja nie jest jednomodalna.
- (f) Metoda przeszukiwania dychotomicznego wymaga aby funkcja była różniczkowalna w badanym przedziale.

3. [3pkt] Używając operacji zachowujących wypukłość, pokaż, że funkcja $f: \mathbb{R}^3 \rightarrow \mathbb{R}$:

$$f(x, y, z) = e^{(x-y)^2} - 2x + z^2,$$

jest wypukła.

Odp:

Funkcja $x - y$ jest liniowa, stąd funkcja $(x - y)^2$ jest wypukła jako złożenie liniowej i wypukłej. Dalej, $e^{(x-y)^2}$ jest wypukła jako złożenie wypukłej niemalejącej z wypukły. Na koniec $f(x, y, z)$ jest wypukła jako suma trzech funkcji wypukłych.

4. [4pkt] Rozważ minimalizację funkcji dwóch zmiennych:

$$f(x, y) = e^{x+y} - 2x + y^2$$

Rozpoczynając od punktu $(x_0, y_0) = (1, -1)$ wykonaj jeden krok:

- metodą spadku wzdłuż gradientu z długością kroku $\alpha = 1$,
- metodą Newtona-Raphsona.

Wyznacz pochodne cząstkowe $f(x, y)$:

$$\frac{\partial f}{\partial x} = e^{x+y} - 2, \quad \frac{\partial f}{\partial y} = e^{x+y} + 2y$$

$$\nabla f(x_0, y_0) = (-1, -1)$$

Wyznacz drugie pochodne cząstkowe $f(x, y)$:

$$\frac{\partial^2 f}{\partial x^2} = e^{x+y}, \quad \frac{\partial^2 f}{\partial x \partial y} = e^{x+y}, \quad \frac{\partial^2 f}{\partial y^2} = e^{x+y} + 2$$

$$\nabla^2 f(x_0, y_0) = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}$$

$$(\nabla^2 f(x_0, y_0))^{-1} = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}$$

Rozwiązanie po pierwszym kroku algorytmu spadku wzdłuż gradientu (napisz wzór ogólny i wartość liczbową):

$$\mathbf{x}_1 = (x_1, y_1) = (1, -1) - 1 \cdot (-1, -1) = (2, 0)$$

Pierwszy krok algorytmu Newtona-Raphsona (napisz wzór ogólny i wartość liczbową):

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$$

5. [2pkt] Przy każdym zdaniu dotyczącym metody gradientów sprzężonych (MGS) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Wektory $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ i $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ są sprzężone względem $\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$.
- (b) Wektory $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ i $\begin{bmatrix} -1 \\ 1 \end{bmatrix}$ są sprzężone względem $\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$.
- (c) Punkt minimum dowolnej funkcji różniczkowalnej jest kombinacją liniową wektorów sprzężonych.
- (d) MGS zastosowany do dowolnej funkcji wypukłej kończy działanie po n krokach (gdzie n to liczba zmiennych).
- (e) MGS jest metodą spadkową.
- (f) Kierunek sprzężony \mathbf{v}_k wybrany w k -tej iteracji MGS jest prostopadły do gradientu w tej iteracji, $\mathbf{g}_k = \nabla f(\mathbf{x}_k)$.

6. [2pkt] Przy każdym zdaniu dotyczącym omówionych metod spadkowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Metoda najszybszego spadku wzdłuż gradientu gwarantuje znalezienie minimum globalnego funkcji różniczkowalnej.
- (b) Wskaźnik uwarunkowania macierzy wypukłej funkcji kwadratowej równy jedności gwarantuje znalezienie minimum w jednym kroku metody Cauchy’ego.
- (c) Metoda Levenberga-Marquardta i spadku wzdłuż gradientu działają identycznie dla funkcji kwadratowej.
- (d) Metoda Newtona-Raphsona zainicjowana dostatecznie blisko minimum (z dodatnio określonym hesjanem) zbiega z kwadratowym rzędem zbieżności.
- (e) Niezerowy gradient wewnątrz dziedziny funkcji oznacza istnienie w tym punkcie kierunku spadkowego.
- (f) Metoda spadku wzdłuż gradientu z regułą Armijo zastosowana do funkcji wypukłej gwarantuje spadek funkcji celu (o ile nie zeruje się gradient).

7. [2pkt] Przy każdym zdaniu dotyczącym metody stochastycznego spadku wzdłuż gradientu (SGD) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Jedna iteracja algorytmu SGD zainicjalizowanego w minimum funkcji nie będzie miała żadnego efektu (nie zmieni aktualnego rozwiązania).
- (b) Kierunek zmian w danej iteracji algorytmu SGD jest średnio równy ujemnemu gradientowi funkcji celu.
- (c) Algorytm SGD można zastosować do optymalizacji regresji liniowej z niekwadratowym błędem o następującej postaci: $f(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{x}_i^\top \mathbf{w})^4$.
- (d) Zbieżność algorytmu SGD jest taka sama jak klasycznego algorytmu spadku wzdłuż gradientu (tj. liniowa).
- (e) Algorytm SGD optymalizujący funkcję wypukłą, ze stałą długością kroku i nieskończonej dużą liczbą iteracji, znajdzie minimum lokalne funkcji.

8. [3pkt] Pokaż, że jeśli \mathbf{v}_k jest dowolnym kierunkiem poprawy w k -tej iteracji dla różniczkowalnej funkcji f , a nowy punkt $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{v}_k$ zostaje wybrany poprzez optymalizację długości kroku (tzn. $\alpha_k = \operatorname{argmin}_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{v}_k)$, załóż, że takie α_k istnieje), to gradient w nowym punkcie jest prostopadły do \mathbf{v}_k , tzn. $\nabla f(\mathbf{x}_{k+1})^\top \mathbf{v}_k = 0$. W szczególności, pokaż, że wynika z tego twierdzenie o “zygzakowaniu” dla metody Cauchy’ego.

Dowód: Niech $g(\alpha) = f(\mathbf{x}_k + \alpha \mathbf{v}_k)$. Z definicji α_k mamy $g'(\alpha_k) = 0$ (pochodna zeruje się gdzieś ponieważ \mathbf{v}_k jest kierunkiem poprawy, a punkt minimum α_k z założenia istnieje), czyli:

$$\begin{aligned} g'(\alpha_k) &= \left. \frac{df(\mathbf{x}_k + \alpha \mathbf{v}_k)}{d\alpha} \right|_{\alpha=\alpha_k} \\ &= \left(\nabla f(\mathbf{x}_k + \alpha \mathbf{v}_k)^\top \mathbf{v}_k \right) \Big|_{\alpha=\alpha_k} \\ &= \nabla f(\mathbf{x}_{k+1})^\top \mathbf{v}_k = 0 \end{aligned}$$

W metodzie Cauchy’ego przyjmujemy jako \mathbf{v}_k kierunek $-\nabla f(\mathbf{x}_k)$, który jest kierunkiem poprawy, ponieważ $\mathbf{v}_k^\top \nabla f(\mathbf{x}_k) = -\nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k) = -\|\nabla f(\mathbf{x}_k)\|^2 < 0$.