

1. [2pkt] Przy każdym zdaniu zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
  - (a) W minimum globalnym funkcji różniczkowalnej (znajdującym się wewnątrz dziedziny) zeruje się gradient.
  - (b) Liniowy rząd zbieżności oznacza, że błąd optymalizacji maleje w tempie wykładniczym.
  - (c) Kwadratowy rząd zbieżności oznacza spadek błędu optymalizacji odwrotnie proporcjonalny do kwadratu liczby iteracji
  - (d) Dwukrotnie różniczkowalne funkcje wypukłe mają w każdym punkcie dodatnio półokreślony hesjan
  - (e) Funkcja wypukła osiąga minimum globalne w dokładnie jednym punkcie dziedziny.
  - (f) Punkt stacjonarny z hesjanem o wartościach własnych mających różne znaki wyklucza minimum lokalne
  
2. [2pkt] Przy każdym zdaniu dotyczącym metod jednowymiarowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
  - (a) Znalezienie minimum globalnego dowolnej funkcji jednowymiarowej jest możliwe z dowolną dokładnością w logarytmicznej liczbie kroków.
  - (b) Metoda złotego podziału wymaga mniej odwołań do funkcji w każdej iteracji niż metoda przeszukiwania dychotomicznego.
  - (c) Metoda bisekcji zawsze znajduje minimum dowolnej funkcji wielomianowej w liczbie kroków równej stopniowi tego wielomianu.
  - (d) Do znalezienia minimum funkcji w danym przedziale wymagane jest by była ona różniczkowalna w tym przedziale.
  - (e) Metoda bisekcji do działania wymaga by funkcja była różniczkowalna na badanym przedziale.
  
3. [3pkt] Używając operacji zachowujących wypukłość, pokaż, że funkcja  $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ :

$$f(x, y, z) = e^{\max\{x+z, y\}} - \ln(x+y),$$

jest wypukła.

Odp:

4. [4pkt] Rozważ minimalizację funkcji dwóch zmiennych:

$$f(x, y) = \frac{1}{2}(x+y)^2 - 8\sqrt{x} - 4\sqrt{y}.$$

Rozpoczynając od punktu  $(x_0, y_0) = (1, 1)$  wykonaj jeden krok:

- metodą spadku wzdłuż gradientu z ustaloną długością kroku  $\alpha = \frac{1}{2}$ ,
- metodą Newtona-Raphsona.

Wyznacz pochodne cząstkowe  $f(x, y)$ :

Stąd  $\nabla f(x_0, y_0) =$

Wyznacz drugie pochodne cząstkowe  $f(x, y)$ :

Stąd  $\nabla^2 f(x_0, y_0) =$

$(\nabla^2 f(x_0, y_0))^{-1} =$

Rozwiązanie po pierwszym kroku algorytmu spadku wzdłuż gradientu (napisz wzór ogólny i wartość liczbową):

$\mathbf{x}_1 = (x_1, y_1) =$

Pierwszy krok algorytmu Newtona-Raphsona (napisz wzór ogólny i wartość liczbową):

$\mathbf{x}_1 = (x_1, y_1) =$

5. [2pkt] Przy każdym zdaniu dotyczącym metody gradientów sprzężonych (MGS) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Wektory  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$  i  $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$  są sprzężone względem  $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix}$ .
  - (b) Wektory  $\begin{bmatrix} 2 \\ -1 \end{bmatrix}$  i  $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$  są sprzężone względem  $\mathbf{A} = \begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix}$ .
  - (c) MGS znajduje dokładne rozwiązanie optymalne funkcji kwadratowej z dodatnio określoną macierzą w  $n$  krokach (gdzie  $n$  to liczba zmiennych).
  - (d) Kierunek sprzężony dobrany w danej iteracji przez MGS może nie być kierunkiem poprawy.
  - (e) Kierunki sprzężone są do siebie ortogonalne.
  - (f) Metody Fletchera-Reevesa i Polaka-Ribière'a są identyczne dla funkcji kwadratowej.
6. [2pkt] Przy każdym zdaniu dotyczącym omówionych metod spadkowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Metoda najszybszego spadku wzdłuż gradientu gwarantuje spadek funkcji celu w każdej iteracji (o ile nie zeruje się gradient).
  - (b) Metoda Levenberga-Marquardta ze zmienną długością kroku gwarantuje spadek funkcji celu w każdej iteracji (o ile nie zeruje się gradient).
  - (c) Duży wskaźnik uwarunkowania macierzy wypukłej funkcji kwadratowej może oznaczać wolną zbieżność algorytmu Cauchy'ego.
  - (d) Metoda Newtona-Raphsona zmniejsza wartość funkcji celu w każdym kroku.
  - (e) Brak kierunku spadkowego w punkcie wewnątrz dziedziny funkcji różniczkowalnej implikuje punkt stacjonarny.
  - (f) Metoda Newtona-Raphsona i spadku wzdłuż gradientu działają identycznie dla funkcji kwadratowej.
7. [2pkt] Przy każdym zdaniu dotyczącym metody stochastycznego spadku wzdłuż gradientu (SGD) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):
- (a) Algorytm SGD zwykle nie porusza się w kierunku ujemnego gradientu funkcji celu.
  - (b) Algorytm SGD optymalizujący funkcję ściśle wypukłą, ze stałą długością kroku i nieskończeniem dużą liczbą iteracji, znajdzie minimum globalne funkcji.
  - (c) Algorytm SGD zbiega wolniej (w funkcji liczby iteracji) niż klasyczny algorytm spadku wzdłuż gradientu.
  - (d) Jest duża szansa, że algorytm SGD zainicjalizowany w minimum funkcji celu w swojej pierwszej iteracji pogorszy funkcję celu.
  - (e) Algorytm SGD jest metodą spadkową i w każdej iteracji zmniejsza wartość funkcji celu (o ile nie jesteśmy w optimum).
8. [3pkt] Udowodnij, że jeśli kierunek w punkcie  $\mathbf{x}_k$  zostaje wybrany jako  $\mathbf{v}_k = -\mathbf{A} \nabla f(\mathbf{x}_k)$ , gdzie  $\mathbf{A}$  jest dowolną macierzą dodatnią określoną, to  $\mathbf{v}_k$  jest kierunkiem poprawy dla funkcji  $f$ . Pokaż, że implikuje to, że metoda Newtona-Raphsona jest metodą spadkową jeśli hesjan funkcji  $f$  jest dodatnio określony w każdym punkcie dziedziny.

# Klucz rozwiązań

Optymalizacja ciągła, Test zaliczeniowy, grupa: B

1. [2pkt] Przy każdym zdaniu zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a)   W minimum globalnym funkcji różniczkowalnej (znajdującym się wewnątrz dziedziny) zeruje się gradient.
- (b)   Liniowy rząd zbieżności oznacza, że błąd optymalizacji maleje w tempie wykładniczym.
- (c)   Kwadratowy rząd zbieżności oznacza spadek błędu optymalizacji odwrotnie proporcjonalny do kwadratu liczby iteracji
- (d)   Dwukrotnie różniczkowalne funkcje wypukłe mają w każdym punkcie dodatnio półokreślony hesjan
- (e)   Funkcja wypukła osiąga minimum globalne w dokładnie jednym punkcie dziedziny.
- (f)   Punkt stacjonarny z hesjanem o wartościach własnych mających różne znaki wyklucza minimum lokalne

2. [2pkt] Przy każdym zdaniu dotyczącym metod jednowymiarowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a)   Znalezienie minimum globalnego dowolnej funkcji jednowymiarowej jest możliwe z dowolną dokładnością w logarytmicznej liczbie kroków.
- (b)   Metoda złotego podziału wymaga mniej odwołań do funkcji w każdej iteracji niż metoda przeszukiwania dychotomicznego.
- (c)   Metoda bisekcji zawsze znajduje minimum dowolnej funkcji wielomianowej w liczbie kroków równej stopniowi tego wielomianu.
- (d)   Do znalezienia minimum funkcji w danym przedziale wymagane jest by była ona różniczkowalna w tym przedziale.
- (e)   Metoda bisekcji do działania wymaga by funkcja była różniczkowalna na badanym przedziale.

3. [3pkt] Używając operacji zachowujących wypukłość, pokaż, że funkcja  $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ :

$$f(x, y, z) = e^{\max\{x+z, y\}} - \ln(x+y),$$

jest wypukła.

Odp:

Funkcja  $\max\{x+z, y\}$  jest wypukła jako maksimum funkcji wypukłych (liniowych). Dalej,  $e^{\max\{x+z, y\}}$  jest wypukła jako złożenie wypukłej niemalejącej z wypukłej. Również  $-\ln(x+y)$  jest wypukła złożenie funkcji wypukłej z liniową, co oznacza, że  $f(x, y, z)$  jest wypukła jako suma dwóch funkcji wypukłych.

4. [4pkt] Rozważ minimalizację funkcji dwóch zmiennych:

$$f(x, y) = \frac{1}{2}(x+y)^2 - 8\sqrt{x} - 4\sqrt{y}.$$

Rozpoczynając od punktu  $(x_0, y_0) = (1, 1)$  wykonaj jeden krok:

- metodą spadku wzdłuż gradientu z ustaloną długością kroku  $\alpha = \frac{1}{2}$ ,
- metodą Newtona-Raphsona.

Wyznacz pochodne cząstkowe  $f(x, y)$ :

$$\frac{\partial f}{\partial x} = x + y - 4/\sqrt{x}, \quad \frac{\partial f}{\partial y} = x + y - 2/\sqrt{y}$$

$$\nabla f(x_0, y_0) = (-2, 0)$$

Wyznacz drugie pochodne cząstkowe  $f(x, y)$ :

$$\frac{\partial^2 f}{\partial x^2} = 1 + 2x^{-3/2}, \quad \frac{\partial^2 f}{\partial x \partial y} = 1, \quad \frac{\partial^2 f}{\partial y^2} = 1 + y^{-3/2}$$

$$\nabla^2 f(x_0, y_0) = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

$$(\nabla^2 f(x_0, y_0))^{-1} = \frac{1}{5} \begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix}$$

Rozwiązanie po pierwszym kroku algorytmu spadku wzdłuż gradientu (napisz wzór ogólny i wartość liczbową):

$$\mathbf{x}_1 = (x_1, y_1) = (1, 1) - \frac{1}{2} \cdot (-2, 0) = (2, 1)$$

Pierwszy krok algorytmu Newtona-Raphsona (napisz wzór ogólny i wartość liczbową):

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{5} \begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} -2 \\ 0 \end{bmatrix} = \begin{bmatrix} 9/5 \\ 3/5 \end{bmatrix}$$

5. [2pkt] Przy każdym zdaniu dotyczącym metody gradientów sprzężonych (MGS) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a)   Wektory  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$  i  $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$  są sprzężone względem  $\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix}$ .
- (b)   Wektory  $\begin{bmatrix} 2 \\ -1 \end{bmatrix}$  i  $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$  są sprzężone względem  $\mathbf{A} = \begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix}$ .
- (c)   MGS znajduje dokładne rozwiązanie optymalne funkcji kwadratowej z dodatnio określoną macierzą w  $n$  krokach (gdzie  $n$  to liczba zmiennych).
- (d)   Kierunek sprzężony dobrany w danej iteracji przez MGS może nie być kierunkiem poprawy.
- (e)   Kierunki sprzężone są do siebie ortogonalne.
- (f)   Metody Fletchera-Reevesa i Polaka-Ribière'a są identyczne dla funkcji kwadratowej.

6. [2pkt] Przy każdym zdaniu dotyczącym omówionych metod spadkowych zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Metoda najszybszego spadku wzdłuż gradientu gwarantuje spadek funkcji celu w każdej iteracji (o ile nie zeruje się gradient).
- (b) Metoda Levenberga-Marquardta ze zmienną długością kroku gwarantuje spadek funkcji celu w każdej iteracji (o ile nie zeruje się gradient).
- (c) Duży wskaźnik uwarunkowania macierzy wypukłej funkcji kwadratowej można oznaczać wolną zbieżność algorytmu Cauchy'ego.
- (d) Metoda Newtona-Raphsona zmniejsza wartość funkcji celu w każdym kroku.
- (e) Brak kierunku spadkowego w punkcie wewnątrz dziedziny funkcji różniczkowalnej implikuje punkt stacjonarny.
- (f) Metoda Newtona-Raphsona i spadku wzdłuż gradientu działają identycznie dla funkcji kwadratowej.

7. [2pkt] Przy każdym zdaniu dotyczącym metody stochastycznego spadku wzdłuż gradientu (SGD) zaznacz, czy jest prawdziwe (P), czy fałszywe (F):

- (a) Algorytm SGD zwykle nie porusza się w kierunku ujemnego gradientu funkcji celu.
- (b) Algorytm SGD optymalizujący funkcję ściśle wypukłą, ze stałą długością kroku i nieskończonej dużą liczbą iteracji, znajdzie minimum globalne funkcji.
- (c) Algorytm SGD zbiega wolniej (w funkcji liczby iteracji) niż klasyczny algorytm spadku wzdłuż gradientu.
- (d) Jest duża szansa, że algorytm SGD zainicjalizowany w minimum funkcji celu w swojej pierwszej iteracji pogorszy wartość funkcji celu.
- (e) Algorytm SGD jest metodą spadkową i w każdej iteracji zmniejsza wartość funkcji celu (o ile nie jesteśmy w optimum).

8. [3pkt] Udowodnij, że jeśli kierunek w punkcie  $\mathbf{x}_k$  zostaje wybrany jako  $\mathbf{v}_k = -\mathbf{A} \nabla f(\mathbf{x}_k)$ , gdzie  $\mathbf{A}$  jest dowolną macierzą dodatnią określoną, to  $\mathbf{v}_k$  jest kierunkiem poprawy dla funkcji  $f$ . Pokaż, że implikuje to, że metoda Newtona-Raphsona jest metodą spadkową jeśli hesjan funkcji  $f$  jest dodatnio określony w każdym punkcie dziedziny.

*Dowód:* Aby pokazać, że  $\mathbf{v}_k$  jest kierunkiem poprawy, trzeba udowodnić, że tworzy on kąt rozwarty z gradientem, tzn.  $\nabla f(\mathbf{x}_k)^\top \mathbf{v}_k < 0$ . Mamy:

$$\nabla f(\mathbf{x}_k)^\top \mathbf{v}_k = -\nabla f(\mathbf{x}_k)^\top \mathbf{A} \nabla f(\mathbf{x}_k) < 0,$$

gdzie ostatnia nierówność wynika z dodatniej określoności macierzy  $\mathbf{A}$ . W metodzie Newtona-Raphsona mamy  $\mathbf{A} = (\nabla^2 f(\mathbf{x}_k))^{-1}$ , która jest dodatnio określona, ponieważ  $\nabla^2 f(\mathbf{x}_k)$  jest dodatnio określony z założenia.